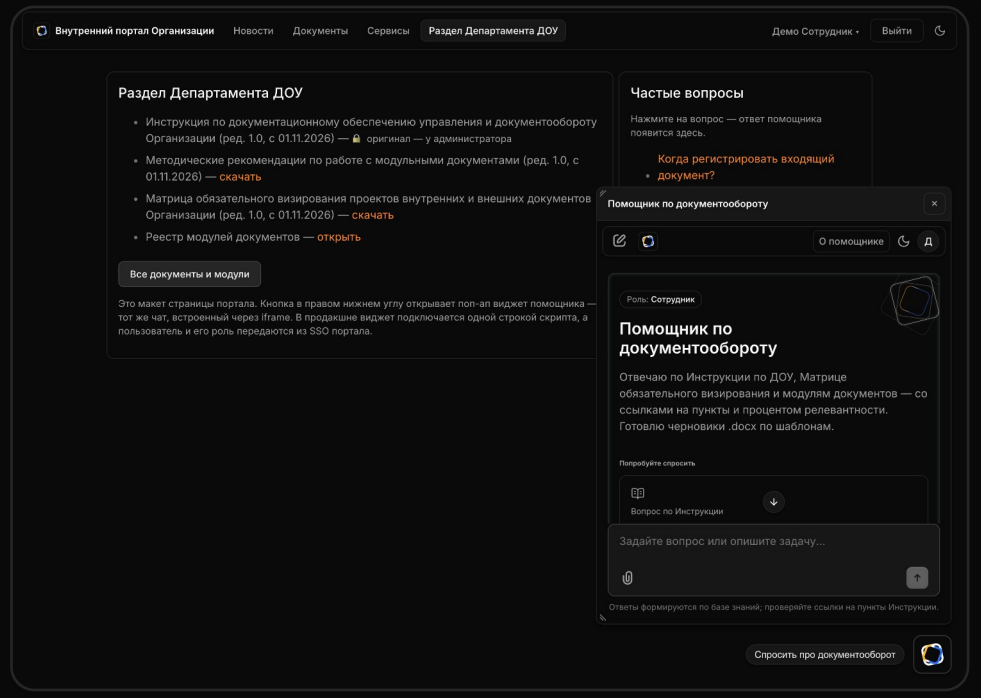
Хакатон «Финтех Хаб» · кейс Банка России

Помощник по документообороту

Найти → понять → сделать

пункт Инструкции · простыми словами · черновик .docx



[Название команды]

[Участники и роли]

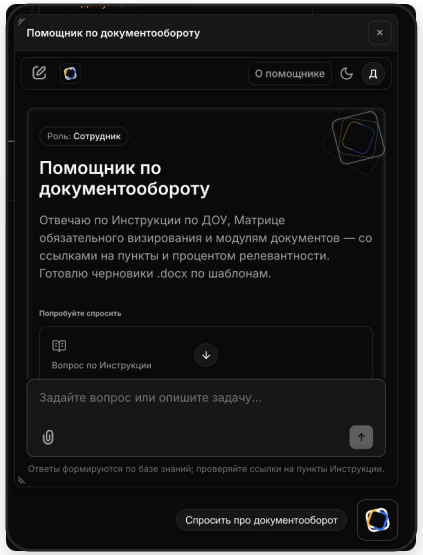
Попробуйте сами: откройте помощника с телефона

217-144-184-227.sslip.io

Спросите своими словами

«скока дней на согласавание приказа»

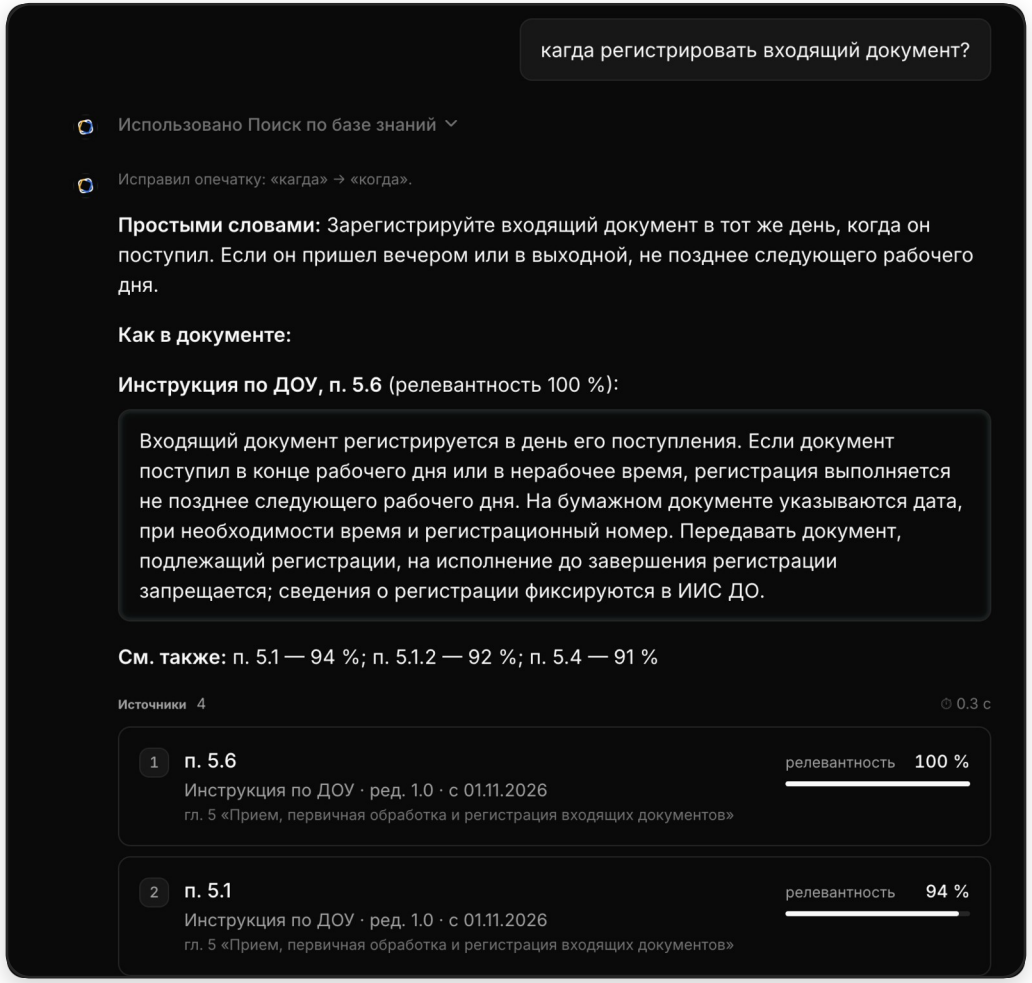
«если отправлю распоряжение на согласавание сегодня когда будет готово?»



Вход по учётной записи: данные для жюри [заполнить]

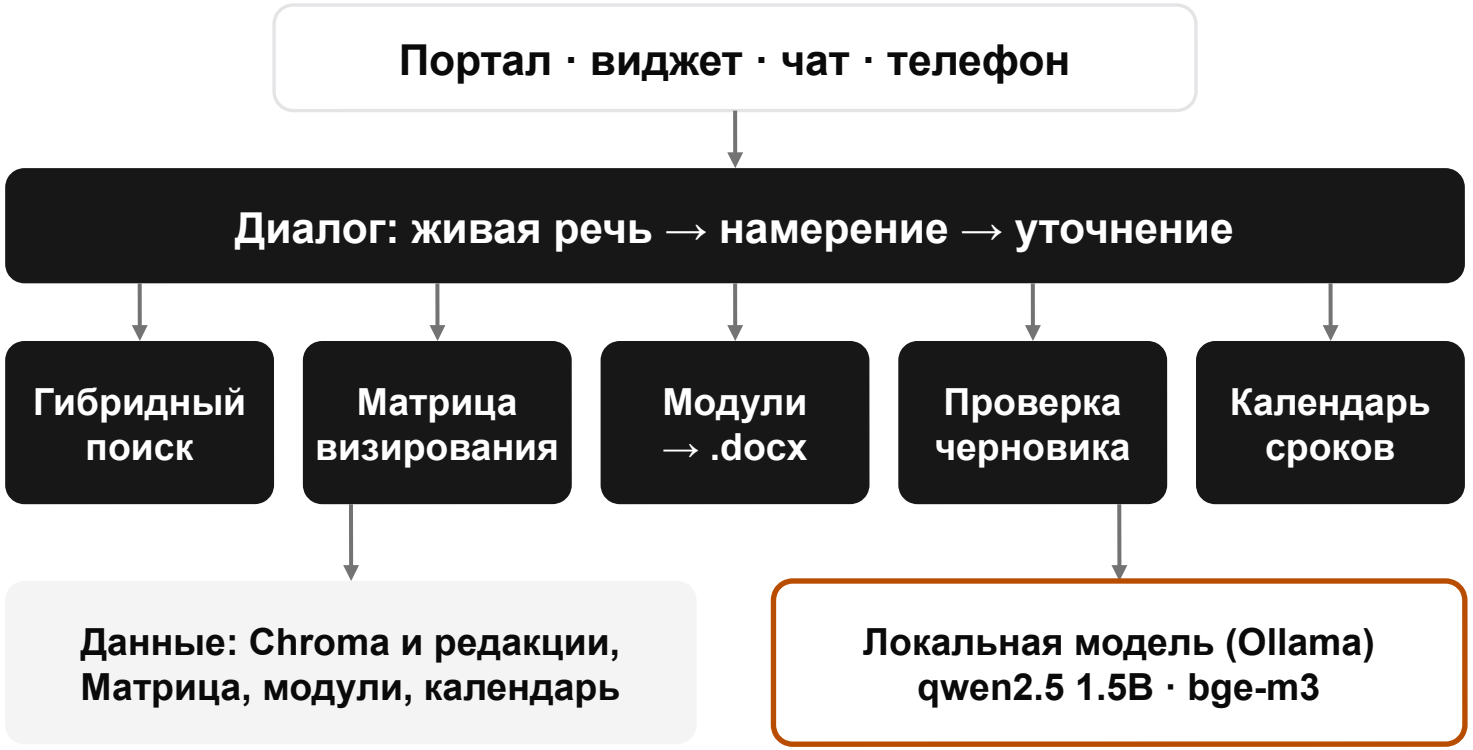
Пять сценариев: от вопроса до документа

1. «скока дней на согласавание…»
2. Нет в базе — честный отказ
3. Уточнение и «а для приказа?»
4. Модуль → вопросы → .docx
5. Черновик, срок датой, телефон



Реальный ответ

Ищет и считает код, модель только объясняет



код

модель: объяснение с проверкой

Ollama, qwen2.5 1.5B
данные в контуре

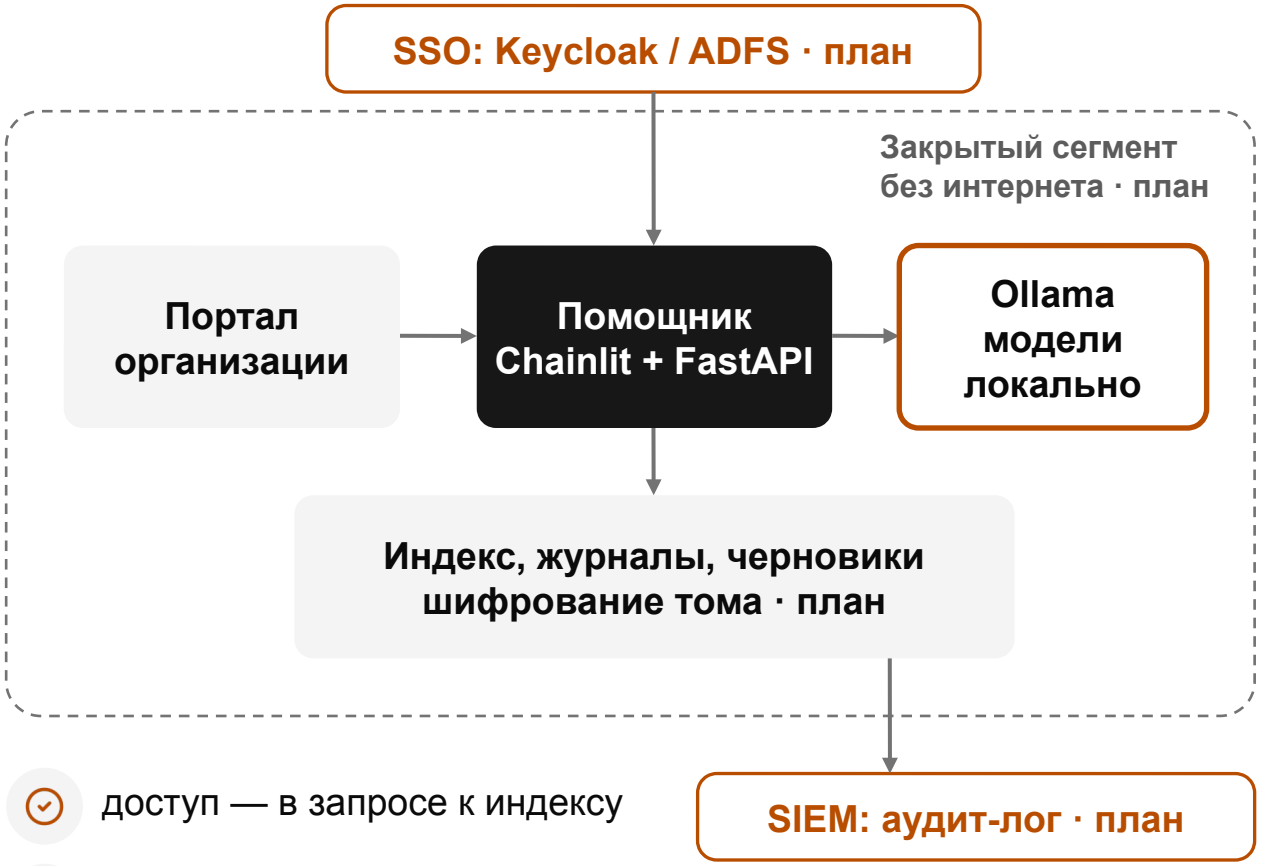
bge-m3 + BM25
смысл и слова

Chroma
доступ в запросе

pymorphy3
живая речь

Chainlit + FastAPI
чат и API

Работает в закрытом контуре на сервере без GPU



- доступ — в запросе к индексу
- исходящих соединений нет

Ресурсы для локальных моделей

Конфигурация	Ресурсы	Ответ: среднее / p95
Проверено: демо-стенд	2 vCPU, 3,8 ГБ ОЗУ, без GPU	3,2 с / 8,6 с
Проверено: ноутбук	Apple M5 Pro, Metal	0,25 с / 0,75 с
Рекомендуется	4 ядра, 8 ГБ ОЗУ или GPU / Apple Silicon	—
Модель 7B	16 ГБ ОЗУ	—
Модель 14B	от 24 ГБ ОЗУ	—

Замеры: README, tests/eval_results.md

Проверено на 99 вопросах и готово к росту

40/40
ожидаемый пункт в источниках

9/9
честный отказ вне базы

0
утечек закрытых пунктов

48/48
разговорные вопросы и диалоги

tests/run_eval.py, 99 вопросов

Обновление базы

- Редакция → архив
- Дифф пунктов
- Документ без кода

Масштабирование

- Виджет — одна строка
- REST API
- Модель — одна строка
- Модуль — YAML

Отличия

- Ссылки — кодом
- Ответ проверяется
- Живая речь
- Офлайн

Дальше: SSO, SIEM, ИИС ДО

Спасибо

github.com/LomashAD/hackathon2026dgtu
217-144-184-227.sslip.io

Архитектура: один сервис, всё локально

Резерв · B1

Браузер

- Чат /?chat
- Портал и виджет
- Портал организации: widget.js
- Вход /login
- Телефон: меню «бургер»

Сервис app

- Chainlit: чат, источники, .docx
- FastAPI: /api/ask, /api/kb/*
- API админ-панели
- Движок диалога
- Живая речь · намерения
- Поиск · Матрица · сроки
- Шаблоны · проверка черновика
- Проверка ответа · доступ

Хранилище storage/

- Chroma: чанки + метаданные
- registry.json: редакции
- matrix.json: Матрица
- logs: аудит, без ответа
- users.json: хеши паролей
- news.yaml: новости

Ollama (локально)

- **qwen2.5:1.5b-instruct**
- **bge-m3: эмбеддинги**

data/ + config.yaml → ingest: разбор → чанк = пункт → эмбеддинги → редакции

Фильтр доступа — условие where в Chroma: уровень роли и status = active

Ответ за шесть шагов: пять из них — код

Резерв · B2

1

Живая речь

опечатки, раскладка, сленг

2

Контекст

«а исходящий?», «его»

3

Намерение

правила; модель — запасной вариант

4

Поиск

20 по смыслу + 20 по словам; 0,8 · близость + 0,2 · слова

5

Порог 0,50

ниже — второй шанс, затем отказ

6

Ответ

простыми словами → цитата → источники с %

Ошибки модели не доходят до сотрудника

- Ссылки, согласующие, сроки — код
- Модель объясняет один пункт, t = 0
- Числа и пункты — только из фрагмента
- ≥ 55 % слов — из пункта
- Ниже порога — честный отказ
- Вместо угадывания — уточнение

Проверка не пройдена — показывается только цитата пункта (app/llm/guard.py)

Показатель (tests/run_eval.py)	Mac, 99 вопросов	Сервер, 89
Ожидаемый пункт в источниках	40/40	33/33
в т.ч. контрольная выборка	10/10	10/10
Честный отказ вне базы и провокации	9/9	7/7
Утечки закрытых пунктов	0	0
Пояснение прошло проверку	25/29 (86 %)	24/29 (83 %)
Живая речь: рабочий / контрольный	24/24 · 24/24	24/24 · 24/24
Время ответа: среднее / p95	0,25 / 0,75 с	3,2 / 8,6 с

Сервер — 2 vCPU без GPU, прогон до добавления 10 вопросов о сроках (README). Mac — tests/eval_results.md, 24.10.2026

Закрытое не попадает ни в поиск, ни в модель

Резерв · B4

Роли и уровни

Сотрудник: public, internal. Администратор: + confidential, архив, админ-панель

Фильтр в запросе

where в Chroma, BM25 по тому же корпусу; провокация p02 — без утечки

ПДн маскируются

в журналах и до передачи модели: ФИО, телефоны, СНИЛС, паспорт

Аудит-лог

кто, когда, что спросил, какие источники получил

Prompt injection

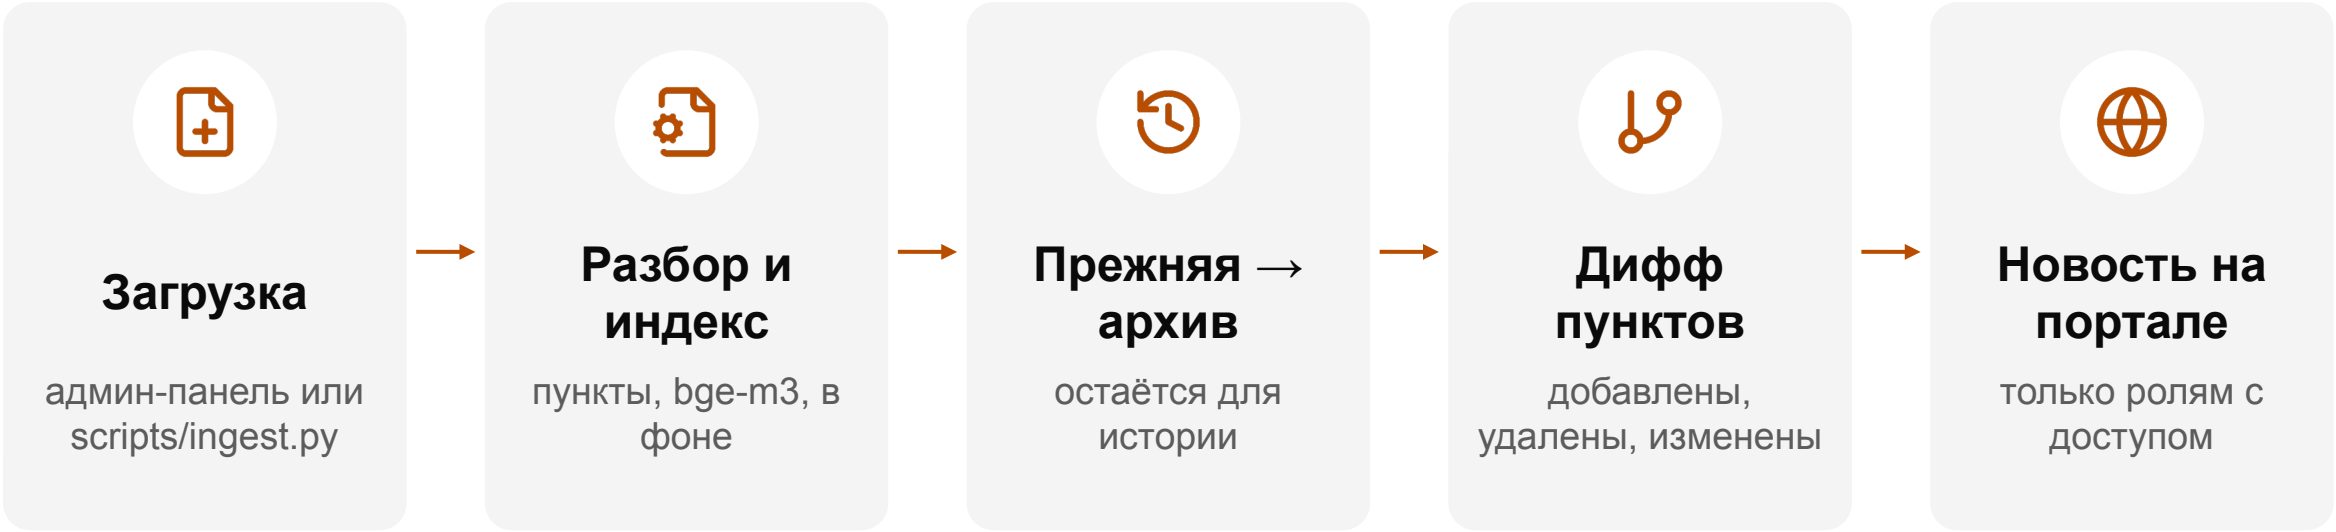
данные в разделителях, ответ проверяется; eval p01 — отказ

Без внешней сети

модели локально; check_egress.sh: только localhost; стенд — 0 исходящих пакетов

Редакции меняются без правки кода

Резерв · B5



- Откат — «Сделать действующей» у архивной редакции
- В каждом источнике — редакция и дата вступления в силу
- Поиск по умолчанию — только действующая редакция
- Администратор может искать и по архиву

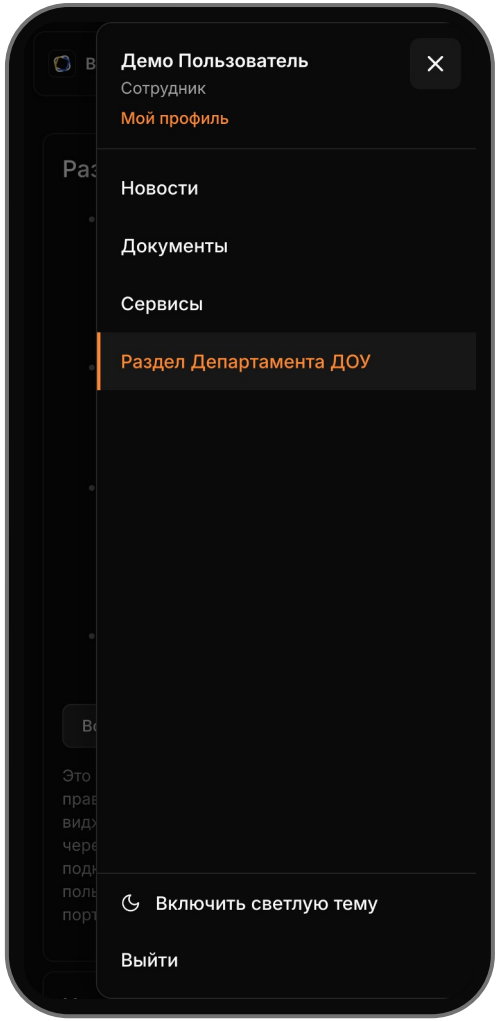
Сроки — датами, портал — с телефона

Резерв · B6



Отправка в субботу, 24.10.2026: отсчёт с понедельника

- Срок — из текста п. 10.3, 10.15, 6.6, 6.7
- Календарь РФ 2026–2027 в YAML: праздники, переносы
- День отправки не считается, выходной — с понедельника
- Срока в Инструкции нет — честный отказ
- До 768 px — меню «бургер» с теми же пунктами



Телефон 390×844

План внедрения: предложение, а не факт

Резерв · B7

Этап 1
Пилот

- Стенд в контуре
- Вопросы сотрудников → eval

→

Этап 2
Портал и ИИС ДО

- Виджет одной строкой
- REST API, грифы из ИИС ДО

→

Этап 3
SSO и SIEM

- Роли из групп AD
- Аудит в SIEM, шифрование тома

→

Этап 4
Другие процессы

- Новые регламенты, справочники
- Новые намерения

Сроки этапов не оценивались: длительность определится по итогам пилота

Честные ограничения и как их снять

Ограничение (README, docs/decisions.md)	Как снять
Модель 1,5B: пояснение проходит проверку в 25 из 29 ответов, иначе — только цитата	qwen2.5 7B / 14B одной строкой config.yaml (16 / от 24 ГБ ОЗУ)
10 вопросов сразу на 2 vCPU: последний ответ ~42 с, пояснение у 4 из 10	Больше ядер или GPU; ожидание модели ограничено 30 с
Первый ответ после простоя ~9 с: загрузка моделей	Прогревочный запрос перед работой
Docker Compose не проверялся	Проверить в контуре заказчика
Календарь 2027 — предварительный	Внести постановление о переносах в YAML
Свои учётные записи; портал — на домене организации	SSO: Keycloak / ADFS
Примеров запросов от заказчика не было — вопросы eval составлены самостоятельно	Дополнить eval реальными вопросами пилота